Projet de Machine Learning for Natural Language Processing

Etienne Marécaux
ENSAE Paris, 3A 2025-2026
etienne.marecaux@ensae.fr

Abstract

Je m'intéresse dans ce projet aux professions de foi des candidats aux élections législatives de 1988 en France. Trois approches distinctes sont ensuite implémentées. J'utilise dans un premier temps l'algorithme de vectorisation Doc2Vec, puis l'algorithme de réduction de dimension TSNE pour construire une carte sémantique des professions de foi. J'observe que les professions de foi se clusterisent en fonction de leur affiliation politique. Dans un second temps, j'effectue un travail sur les stratégies de citation de personnalités politiques par parti. Enfin et dans un troisième temps, je conduis un travail de prédiction du parti politique en fonction de la transcription de la profession de foi, en utilisant deux techniques d'apprentissage différentes : un algorithme Random Forest et un algorithme SVR. Les deux algorithmes fournissent des résultats de prédiction satisfaisants. L'ensemble du code est disponible sur un répertoire GitHub à l'adresse en pied de page[1].

1 Problématiques

L'enjeu central de cette étude est d'évaluer dans quelle mesure le langage politique est un marqueur important de l'identité d'un parti. Je tenterai de répondre à cette problématique globale en utilisant plusieurs techniques de traitement automatique du langage (NLP) :

- **L'homogénéité sémantique dans les partis politiques :** Quel parti politique est le plus homogène dans ses discours ? Pour répondre à cette question, les algorithmes *Doc2Vec*, puis *TSNE*, seront implémentés sur le dataset d'étude, afin de construire une carte sémantique en deux dimensions.
- **Les stratégies de citations :** Quels partis politiques citent plutôt leur leader ? Quels partis, au contraire, critiquent les figures politiques des partis adverses ? Pour répondre à cette problématique, je mettrai en place un algorithme de *Named-entity Recognition* (NER).
- **La capacité prédictive du discours politique :** Est-il possible de prédire le parti politique associé à une profession de foi ? Pour répondre à cette question, j'implèmenterai deux algorithmes prédictifs en régression afin de comparer leurs performances : *Random forests* et *SVR*.

Répondre à ces trois problématiques sera l'occasion de mettre en œuvre plusieurs algorithmes de NLP étudiés dans le cours, et d'apporter une réponse plus globale à propos de l'influence de l'idéologie politique sur le discours électoral.

2 La base de données Archelec

La base de données Archelec [1] contient les transcriptions de professions de foi des candidats à plusieurs élections législatives et présidentielles françaises, ainsi que des métadonnées décrivant

[1] https://github.com/PSCfin/NLP-project.git

le candidat principal, son colistier et leurs soutiens politiques. J'ai choisi de me concentrer sur les données des élections législatives de 1988, disponibles au début de ce projet.

Le jeu de données brut contient 3540 fichiers, et contient les professions de foi du premier et du second tour. Les transcriptions sont obtenues par OCR en dehors de cette étude, et les métadonnées sont proposées sous forme de fichier *CSV*. Un identifiant unique liant la ligne du *CSV* et la profession de foi associée permet de faire la "jointure" entre les métadonnées et les fichiers textuels issus de l'OCR.

Chaque transcription est associée à une liste de partis politiques soutenant le candidat, mais il est nécessaire de traiter cette liste pour situer le candidat sur l'échiquier politique. Je classe d'abord chaque parti dans l'une des 8 grandes catégories allant de l'extrême gauche à l'extrême droite (voir tableau 1) et associe à chaque catégorie un indice compris entre 0 (extrême gauche) et 1 (extrême droite). Un indice politique synthétique est calculé comme la moyenne de toutes les entrées de la liste des soutiens. Les candidats sans soutien ou soutenus uniquement par des partis non affiliés sont éliminés. Le nombre final de professions de foi est de 1101.

Table 1: Nombre de professions de foi pour chaque parti politique.

Parti	Extrême-gauche	Gauche	Centre gauche	Verts
Professions	9	343	16	13
Parti	Centre	Centre droit	Droite	Extrême-droite
Professions	6	228	248	238

3 État de l'art

L'évolution du Traitement du Langage Naturel (NLP) a été marquée par une transition des méthodes statistiques classiques vers des représentations vectorielles denses, permettant de capturer la sémantique profonde des documents.

Afin de parer aux problématiques de poids uniforme introduites par la méthode *Bag of Words*, l'algorithme TF-IDF a été développé. La méthode TF-IDF (*Term Frequency-Inverse Document Frequency*) est une référence pour l'évaluation de l'importance de termes au sein d'un corpus de documents. Introduite par Karen Spärck Jones en 1972 [2], cette mesure statistique pondère la fréquence d'un mot par l'inverse de sa fréquence dans l'ensemble des documents. Elle permet ainsi d'atténuer l'impact des petits mots courants (les stop words) pour isoler les mots les plus discriminants.

La Reconnaissance d'Entités Nommées (**NER**) est une tâche visant à identifier et classifier des entités (noms propres, dates, lieux) dans un texte. Inventée lors de la Sixth Message Understanding Conference (MUC-6), la NER a formalisé la tâche et permet une classification rapide et performante, souvent aujourd'hui à base de réseaux de neurones récurrents ou de transformers, comme le modèle de langage BERT.

Enfin, la visualisation de vecteurs de haute dimension (issus des algorithmes de vectorisation Doc2Vec ou TF-IDF) nécessite des techniques de réduction de dimensionnalité non-linéaires. L'algorithme **t-SNE** (*t-distributed Stochastic Neighbor Embedding*), développé pour la première fois par van der Maaten et Hinton en 2008 [3], est devenu le standard pour projeter des données complexes dans un espace en deux ou trois dimensions. Il préserve particulièrement bien la structure locale des données, facilitant ainsi l'identification visuelle de clusters thématiques.

4 Les méthodes et algorithmes utilisés

Première partie. Afin de traiter de l'homogénéité sémantique dans les partis politiques, j'ai choisi l'algorithme *Doc2Vec*, car il permet de représenter des documents (ou discours) sous forme de vecteurs de caractéristiques tout en conservant les relations sémantiques entre les mots. Cette approche

est particulièrement adaptée à ce contexte puisqu'elle permet de rendre compte de significations sémantiques plus profondes que des modèles de type *Bag of Words* apr exemple. J'utilise ensuite l'algorithme t-Distributed Stochastic Neighbor Embedding (*TSNE*) afin de réduire la dimension des vecteurs obtenus. Cela permet de faciliter la visualisation de l'homogénéité des professions de foi au sein d'un même parti. Cet algorithme permet de sélectionner de manière optimisée deux dimensions significatives des discours encodés, et d'ainsi observer clairement la proximité entre deux professions de foi.

Deuxième partie. La problématique ici est de savoir quels partis politiques citent fréquemment leur propre leader, ou au contraire, critiquent les figures des partis adverses. J'ai naturellement choisi pour ce faire la *Named-entity Recognition* (NER). Cette tâche d'extraction d'information permet de catégoriser des entités selon leur genre : noms de lieux, noms de personnes...

Troisième partie. La prédiction du parti politique associé à une profession de foi repose sur l'utilisation d'algorithmes de régression (le parti politique étant converti en un indice compris entre 0 et 1). Je choisis pour cela deux algorithmes de Machine Learning afin de comparer leurs performances : les arbres de décision (*Random forests*) et la *Support Vector Regression* (SVR). Le contexte de l'analyse de textes politiques étant propice au sur-apprentissage, les forêts d'arbres aléatoires et indépendants permettent dans une large mesure d'éviter ce type de problème. C'est pourquoi je m'attends à ce que ce modèle soit performant sur mon jeu de données. L'algorithme SVR, quant à lui, est un algorithme simple (appliqué à mon indice de position politique entre 0 et 1, qui peut être facilement généralisé et qui ne nécessite pas, contrairement à un réseau de neurones, un dataset de grande taille pour être performant. C'est pourquoi je le choisis en tant qu'algorithme plus basique pour effectuer cette tâche.

Pour encoder les documents et entraîner les modèles sur la prédiction de parti politique, j'utilise l'algorithme *Term-Frequency Inverse Document-Frequency* (TF-IDF), qui permet d'amplifier le poids d'un mot selon sa fréquence d'apparition dans un document, en comparaison à sa fréquence d'apparition dans l'ensemble du corpus. Cet algorithme sera particulièrement plus performant que *Bag of Words* dans le cadre de cette étude, puisque *Bag of Words* assigne à chaque mot le même poids à fréquence égale. Cela risque d'être handicapant dans le contexte de professions de foi politiques, qui usent de manière répétée de mots lourds, communs et répandus.

5 Implémentation et résultats

5.1 Homogénéité sémantique dans les partis politiques

J'implémente dans un premier temps une projection en deux dimensions des embeddings issus de Doc2Vec en utilisant l'algorithme t-SNE. L'affiliation politique est représentée par une couleur allant du rouge (extrême-gauche) au bleu (extrême-droite). On observe bien que les transcripts se regroupent en fonction de l'affiliation politique. Cela montre que la proximité dans l'espace de haute dimension induit est bel et bien associée à l'idéologie politique. En d'autres termes, il existe des champs sémantiques partagés à l'échelle d'un parti, qu'il est possible de capter à travers l'encodage en haute dimension.

Il est également à noter que la proximité sémantique entre les professions de foi d'un même parti semble d'autant plus importante que le parti est situé aux extrêmes de l'échiquier politique, ce qui constitue un résultat instinctif mais rassurant.

Figure 1: Projection en basse dimension des embeddings des professions de foi

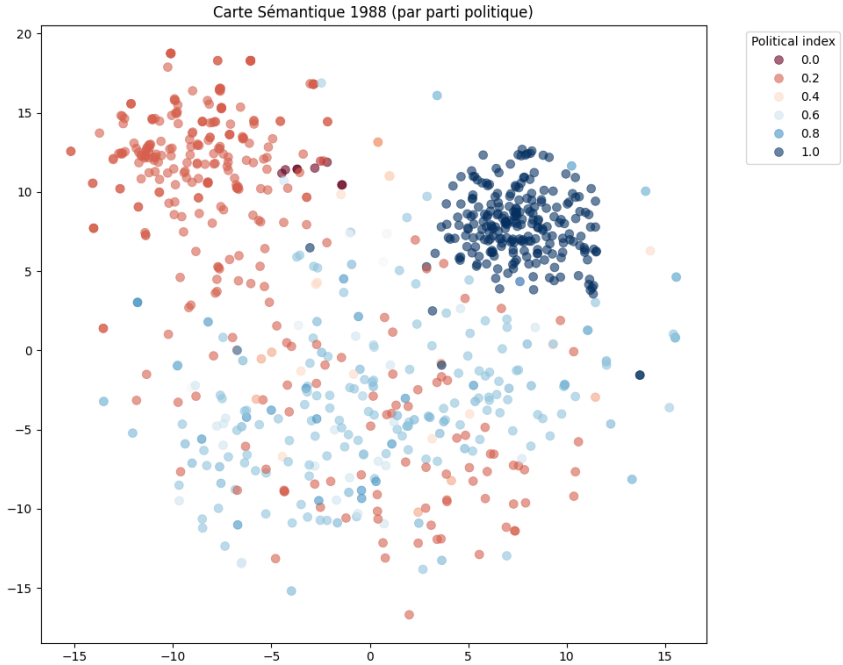

5.2 Stratégies de citations

Afin de mettre en pratique la *Named-entity Recognition* (NER) étudiée dans le cours, je travaille dans cette partie à l'identification de stratégies de citation de figures politiques dans les professions de foi des candidats. Pour ce faire, j'ai décidé d'utiliser le modèle `fr_core_news_sm`, issu de la bibliothèque spaCy. C'est le modèle linguistique de base pour la langue française, intégrant une reconnaissance d'entités nommées.

Je comptabilise, à l'aide de ce modèle, chaque entité de type *PER* (personne), et en extrait les dix personnalités les plus citées. Je retrouve alors les figures politiques majeures de l'époque. Je décline ensuite ces citations selon le parti associé à la profession de foi correspondante et obtiens le tableau suivant résumant les principaux résultats.

Table 2: Nombre de citations par entité pour chaque parti politique.

	François Mitterrand	Jacques Chirac	Jean-Marie Le Pen	Président de la République
Gauche (0.2)	424	62	149	219
Droite (0.7)	19	3	0	21
Extrême-Droite (1.0)	230	1	187	0

On observe alors deux stratégies différentes. La droite, qui vient de perdre les élections présidentielles, cite peu (voire pas) son leader Jacques Chirac. De manière générale, la droite choisit de ne pas citer d'entités de type personnalité. A l'inverse, la gauche et l'extrême-droite rappellent fréquemment le nom de leurs leaders respectifs : François Mitterrand, qui vient d'être réélu Président de la République française, et Jean-Marie Le Pen. En outre, les deux partis choisissent également de nommer fréquemment le leader de l'autre parti, sûrement à des fins de décrédibilisation ou d'opposition.

Enfin, il est à noter l'omniprésence de l'entité "Président de la République" dans le discours de la gauche, une tendance qui voit sans doute sa cause dans les récents résultats des élections présidentielles en ce temps.

5.3 Prédiction du parti politique

Dans cette dernière partie, j'espère confirmer ce que les deux premiers travaux ont exhibé : le discours politique est un marqueur de l'idéologie. La carte en faible dimension issue de l'algorithme t-SNE a montré que les techniques de traitement du langage pouvaient capter, rien que dans la vectorisation des professions de foi, une proximité sémantique intrapartisane. Je mets en œuvre ici deux algorithmes de régression afin de prédire l'indice de parti politique (entre 0 et 1) associé à une profession de foi.

5.3.1 Random forests

J'implémente dans un premier temps un algorithme *Random forests*. Je sépare mon jeu de données en un set d'entraînement et un set de test, suivant la loi 80% entraînement et 20% test. La séparation est faite de manière aléatoire, mais je fixe l'aléa pour avoir de la reproductibilité entre les compilations.

J'encode ensuite les professions de foi avec l'algorithme *Term-Frequency Inverse Document-Frequency* (TF-IDF). Je fournis à l'algorithme la liste usuelle des stop words français, auxquels j'ajoute les mots les plus influents de la prédiction de l'algorithme (préalablement testé avec uniquement les stop words standards) : droite, gauche, centre...

J'entraîne la forêt aléatoire avec 100 arbres indépendants, puis j'affiche les résultats sur le set d'entraînement (qui contient environ 200 documents). Sur la figure ci-dessous, l'abscisse est la position politique réelle, et l'ordonnée la position politique prédite.

Figure 2: Résultats de prédiction de l'indice de position politique d'un *Random forests* à 100 estimateurs

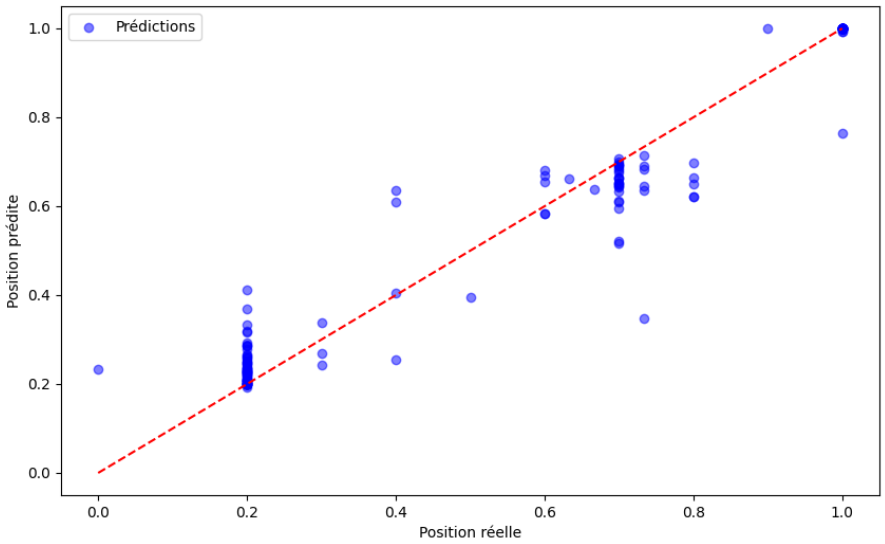

Les résultats sont plutôt concluants : avec une erreur quadratique moyenne MSE $= 0.0053$, l'algorithme est performant. On cherche à présent à déterminer quels sont les mots qui ont le plus fort impact sur la prédiction de l'algorithme.

La prédiction effectuée par *Random forests* n'est pas facilement interprétable. En effet, il s'agit d'une moyenne de 100 estimateurs indépendants, qui eux-mêmes ne disposent pas d'une formule de régression comme ce sera le cas pour l'algorithme SVR. Afin de contourner ce problème, la figure ci-dessous affiche les mots avec la plus haute *permutation importance*.

La *permutation importance* d'un terme est définie comme la différence entre l'erreur quadratique moyenne de la prédiction effectuée sur un document contenant ce terme et la prédiction effectuée sur le même document auquel on aurait soustrait ce terme. Cette mesure est donc un marqueur significatif de l'importance d'un mot dans une prédiction.

Figure 3: Les 20 termes les plus influents (au sens de la *permutation importance*) dans la prédiction de l'algorithme *Random forests*

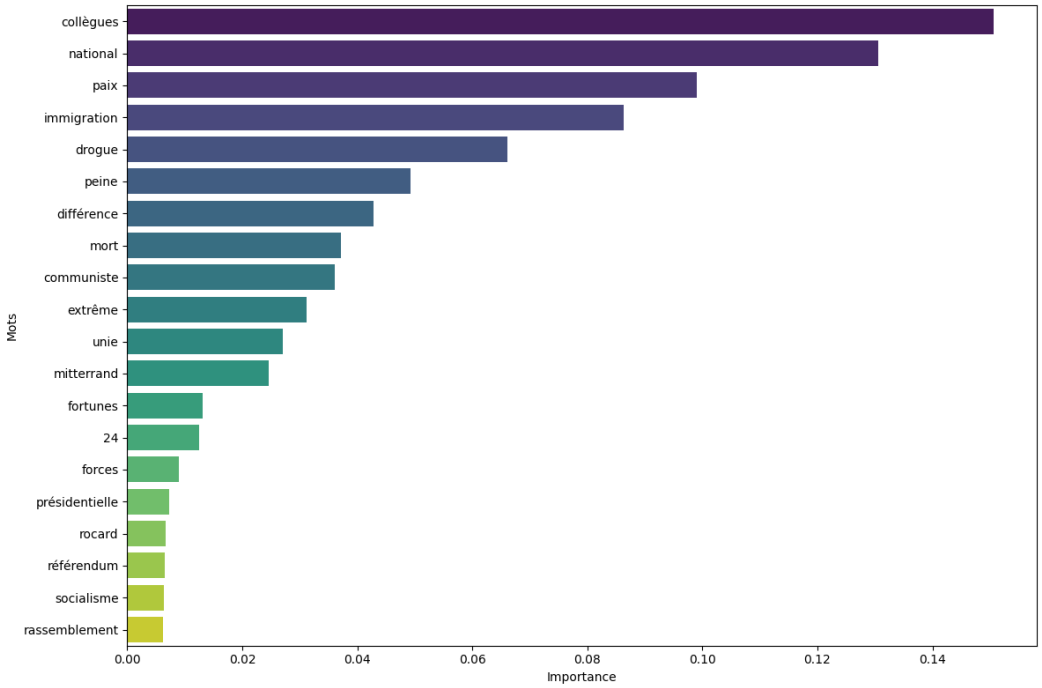

Il est intéressant de noter que des termes marqueurs du débat politique sont retrouvés dans les mots les plus discriminants pour l'algorithme : paix, immigration, drogue, peine, mort... Même si cette mesure est difficilement interprétable, elle permet de donner une idée du processus décisionnel moyen de la forêt implémentée.

5.3.2 Support Vector Regression (SVR)

Afin d'implémenter une SVR, j'utilise le même set d'entraînement et le même set de test que pour l'algorithme *Random forests*. J'encode de la même manière les professions de foi à l'aide de TF-IDF, exception faite de l'autorisation ici de capter les expressions de deux mots consécutifs dans une profession de foi, en plus des termes uniques.

L'avantage de la SVR est qu'elle constitue un algorithme interprétable. On octroie à l'algorithme un nombre maximal de paramètres, ici les mots (et groupes de mots), et la sortie est une expression de régression de l'indice de position politique sur ces paramètres. Il sera donc ensuite possible d'étudier précisément les mots à fort impact sur la prédiction de l'algorithme, et de les comparer à ceux issus de la *permutation importance* de l'algorithme *Random forests*.

Figure 4: Résultats de prédiction de l'indice de position politique avec une SVR

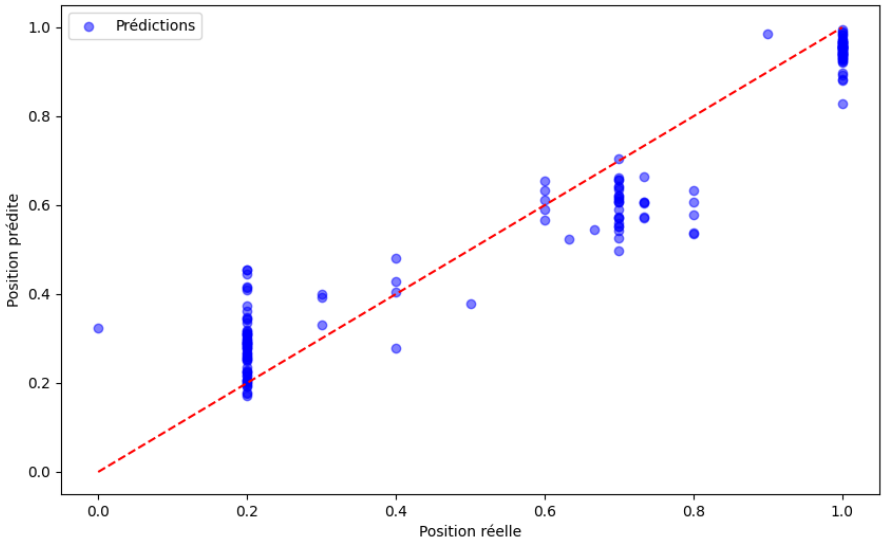

La performance de prédiction est légèrement inférieure à celle obtenue avec *Random forests* : avec une erreur quadratique moyenne MSE $= 0.0105$, l'algorithme est tout de même performant. Il est à présent facile de déterminer l'influence de mots et de groupes de mots sur la prédiction effectuée ; il suffit simplement de regarder les coefficients associés dans la régression.

Table 3: Coefficients dans la régression pour des mots influents sélectionnés.

Expression	Coefficient	Expression	Coefficient
Pouvoirs	0.156	Majorité présidentielle	-0.203
Famille	0.128	Rassemblement forces	-0.176
Économique	0.112	Paix	-0.160
Entreprise	0.116	Égalité	-0.120
Immigration	0.010	Femmes	-0.115

La SVR utilise positivement des expressions typiques du discours électoral de droite (pouvoir, famille, entreprise...) pour augmenter l'indice de position de la prédiction, et des expressions typiques du discours électoral de gauche de l'époque (majorité présidentielle, paix, égalité...) pour diminuer l'indice de position de la prédiction. Ces coefficients sont tout à fait satisfaisants et montrent notamment que le modèle n'a pas sur-appris.

Conclusion

En conclusion, j'ai implémenté et mis en œuvre pour ce projet plusieurs techniques algorithmiques introduites dans le cours de Machine Learning for Natural Language Processing. L'objectif était de montrer que l'idéologie politique transpire dans le disocurs électoral. A cette fin, j'ai utilisé la base de données Archelec et me suis plus spécifiquement focalisé sur les élections législatives de 1988 en France. Au travers de trois expériences distinctes, j'ai montré qu'il était possible de capter algorithmiquement des différences sémantiques, stratégiques et rédactionnelles entre les différents partis impliqués lors de cette élection.

L'une des limitations (et regret) que j'apporte à ce projet est la non-réussite dans l'implémentation de techniques de topic modelling. Confronté pour la première fois à un sujet de NLP, la structure des documents (en-têtes identiques, jargon très commun...) aura été une barrière à toutes mes nombreuses et infructueuses tentatives en ce sens. J'ai volontairement laissé à la fin du Notebook (disponible sur le GitHub) mes derniers essais qui utilisaient le modèle de langage BERT. J'avais également préalablement testé des techniques comme LDA et NMF sans succès. Le principal problème rencontré était le fait que les thèmes retenus par les différents algorithmes étaient trop vagues, ou tous quasiment identiques ; un problème que je n'ai jamais réussi à régler, même en forçant les topics ou en utilisant du *Zero Shot*.

Références

[1] Gaultier-Voituriez, O. (2022) Archelec, les archives électorales françaises de la Ve République, du papier au numérique : reflet fidèle ou distorsion ? *Presses universitaires du Septentrion*.

[2] Spärck Jones, K. (1972) *A Statistical Interpretation of Term Specificity and Its Application in Retrieval.* Journal of Documentation, 28(1), 11–21.

[3] van der Maaten, L. & Hinton, G. (2008) *Visualizing Data using t-SNE.* Journal of Machine Learning Research, 9, 2579–2605.